

شبکه های عصبی

استاد: محمد باقر منهاج



موضوعات

• فصل هفتم

- **-** مقدمه
- مبانی بهینه سازی و نقاط بهینه
 - روشهای می نیمم سازی
- یادگیری ویدرو-هوف و شبکه آدالاین
 - الگوريتم LMS
- کاربرد شبکه آدالاین در فیترهای تطبیقی



فصل ۷ شبكه هاى آدالاين و یادگیری LIMS



مقدمه

- شبکه آدالاین با قانون یادگیری ویدرو هوف (معروف به قانون LMS) در سال ۱۹۶۰ و بعد از شبکه پرسپترون با قانون یادگیری SLPR به وجود آمد.
- شبکه آدالاین شبیه پرسپترون است ولی با تابع تبدیل خطی (به جای آستانه دو مقداره)
 - محدودیت شبکه های پرسپترون و آدالاین:
 - فقط توانایی طبقه بندی الگوهایی را دارند که به طور خطی از هم جداپذیرند.
 - قانون SLPR:
 - همگرایی به یک جواب را در صورت وجود تضمین میکند.
- نسبت به نویز خیلی حساس است، زیرا خط مرزی خیلی نزدیک الگوهای یادگیری است.
 - قانون LMS:
 - خيلي قويتر از SLPR
 - دارای کاربردهای فراوان در مهندسی و به خصوص پردازش سیگنال



مقدمه

- شبکه های آدالاین
- مناسب برای تقریب خطی یک تابع یا اجرای عمل شناسایی الگو
 - دارای منحنی سطح خطای اجرایی سهموی
 - دارای مزیت برخورداری از یک نقطه مینیمم
 - یادگیری از نوع با ناظر
- پارامترهای شبکه به نحوی تنظیم می شوند که شاخص اجرایی میانگین مربعات خطا بهینه شود.
- قانون یادگیری LMS تقریبی از الگوریتم بیشترین شیب در حداقل کردن شاخص اجرایی
- حتی در صورت عدم وجود جواب (در این حالت قانون SLPR همگرا نخواهد شد) ، باز به جایی که میانگین مربعات خطا حداقل است، همگرا می شود.
 - نسبت به نویز کمتر حساس



مبانی بهینه سازی و نقاط بهینه

- پایه همه تکنیکهای یادگیری از نوع عملکردی
- در یادگیری عملکردی پارامترهای شبکه به نحوی تنظیم می شوند که عملکرد شبکه بهینه شود.
- قدم اول: تعریف عملکرد و تعیین شاخص عملکرد. (معمولا سطح اجرایی میانگین مربعات خطا)
- قدم دوم: جستجو در فضای پارامترهای شبکه برای تنظیم آنها به طوریکه معیار اجرایی عملکرد کاهش یابد.



مبانی بهینه سازی: بسط تیلور و تقریب توابع

 $\underline{\mathbf{x}}$ بسط تیلور تابع اسکالر $\mathbf{F}(\underline{\mathbf{x}})$ با متغیر برداری

$$F(\underline{x}) = F(\underline{x}^*) + \nabla_{\underline{x}} F^T(\underline{x}^*) (\underline{x} - \underline{x}^*) + \frac{1}{2} (\underline{x} - \underline{x}^*)^T \nabla^2_{\underline{x}} F(\underline{x}^*) (\underline{x} - \underline{x}^*) + \dots$$

• بردار گرادیان و ماتریس هسیان تابع F به ترتیب برابرند با:

$$\nabla_{\underline{x}} F(\underline{x}) = \begin{bmatrix} \frac{\partial F}{\partial x_{1}}, \frac{\partial F}{\partial x_{2}}, \dots, \frac{\partial F}{\partial x_{n}} \end{bmatrix}^{T} \qquad \nabla_{\underline{x}}^{2} F(\underline{x}) = \begin{bmatrix} \frac{\partial^{2} F(\underline{x})}{\partial^{2} x_{1}} & \frac{\partial^{2} F(\underline{x})}{\partial x_{1} \partial x_{2}} & \dots & \frac{\partial^{2} F(\underline{x})}{\partial x_{1} \partial x_{n}} \\ \frac{\partial^{2} F(\underline{x})}{\partial x_{2} \partial x_{1}} & \frac{\partial^{2} F(\underline{x})}{\partial x_{2} \partial x_{1}} & \frac{\partial^{2} F(\underline{x})}{\partial x_{2} \partial x_{n}} & \dots & \frac{\partial^{2} F(\underline{x})}{\partial x_{2} \partial x_{n}} \\ \vdots & & & \vdots & & \vdots \\ \frac{\partial^{2} F(\underline{x})}{\partial x_{n} \partial x_{1}} & \frac{\partial^{2} F(\underline{x})}{\partial x_{n} \partial x_{2}} & \dots & \frac{\partial^{2} F(\underline{x})}{\partial x_{n} \partial x_{n}} \end{bmatrix}$$



مبانی بهینه سازی: مشتقات برداری جهت دار

$$D_{\underline{p}}F(\underline{x}) = \frac{\underline{p}^T \nabla_{\underline{x}} F(\underline{x})}{\|\underline{p}\|}$$

 \mathbf{p} مشتق تابع \mathbf{p} در مسیر بردار

• مشتق دوم تابع F در مسیر بردار \underline{p}

$$D^{2}_{\underline{p}}F(\underline{x}) = \frac{\underline{p}^{T}\nabla^{2}_{\underline{x}}F(\underline{x})\underline{p}}{\|\underline{p}\|^{2}}$$

• سوال:

در چه مسیرهایی مقدار مشتق برداری ماکزیمم، مینیمم یا صفر خواهد بود؟



مبانی بهینه سازی: شرایط لازم برای نقاط بهینه

• برای اینکه *X نقطه مینیمم تابع F باشد

$$\nabla_{\underline{x}} F(\underline{x}^*) = 0$$

- شرط درجه اول:

$$\nabla^2_{x} F(\underline{x}^*) > 0$$

نقاط ایستای تابع F

- شرط درجه دوم: (ماتریس مثبت معین)

• شرط لازم برای نقطه مینیمم *X:

$$\nabla_{\underline{x}} F(\underline{x}^*) = 0 \qquad \nabla^2_{\underline{x}} F(\underline{x}^*) \ge 0$$

• شرط لازم و كافي براي نقطه مينيمم *X:

$$\nabla_{\underline{x}} F(\underline{x}^*) = 0$$
 $\nabla^2_{\underline{x}} F(\underline{x}^*) > 0$

• شرط کافی برای اینکه *X زین اسبی باشد، ماتریس هسیان نامعین باشد.



مبانی بهینه سازی: توابع درجه دوم

$$F(\underline{x}) = \frac{1}{2} \underline{x}^T A \underline{x} + \underline{b}^T \underline{x} + c \quad , A^T = A$$

 متقارن بودن A الزامی نیست زیرا هر ماتریس نامتقارن را می توان به متقارن تبدیل کرد. چگونه؟

$$\nabla_{x} F(\underline{x}) = \underline{b} + A\underline{x}$$

$$\nabla^2_{x} F(\underline{x}) = A$$

- شاخص عملکردی میانگین مربعات خطا از نوع درجه دوم می باشد.
- تمامی توابع با مشتقات پیوسته مرتبه دوم حول یک ناحیه به اندازه کافی کوچک مثل تابع درجه دوم عمل می کند. چرا؟
- بیشتر الگوریتمهای بهینه سازی با تابع عملکرد مرتبه دوم پس از تعداد محدودی تکرار به نقطه بهینه خواهند رسید.



مبانی بهینه سازی: توابع درجه دوم و ساختار ویژه

- در توابع درجه دوم ساختار ویژه (مقادیر و بردارهای ویژه) ماتریس هسیان نقش مهمی در مینیمم کردن توابع دارند.
 - به علاوه مقادیر و بردارهای ویژه دارای تعابیر فیزیکی نیز هستند.

تمرين:

ارتباط مقادیر و بردارهای ویژه ماتریس هسیان در مینیمم سازی چیست؟ با توجه به نقشی که آنها در مثبت معین یا منفی معین کردن یک ماتریس دارند، توضیح دهید. (در بخش ۷-۲-۸ کتاب آمده است.)



روند مينيمم سازى: الگوريتم كلي

• روند بازگشتی: تخمین جدید از روی تخمین فعلی قابل محاسبه است

$$\underline{x}(k+1) = \underline{x}(k) + \alpha(k)p(k)$$

بردار جستجو $\underline{\mathbf{p}}(\mathsf{k})$ تخمین فعلی نقطه مینیمم تابع $\alpha(k)$ ، \mathbf{F} نرخ یادگیری و $\underline{\mathbf{p}}(\mathsf{k})$ بردار جستجو است.

- در روشهای مختلف مینیمم سازی، بردار جستجو متفاوت است.
- p(k) به گونه ای تعیین می شود که مقدار تابع F در هر مرحله کاهش یابد.
 - بردار جستجو از روی اطلاعات گرادیان و هسیان تابع محاسبه می شود.



روند مینیمم سازی: روش بیشترین نزول (SD)

- دیدیم که اگر مسیر p(k) در خلاف جهت گرادیان باشد، مقدار مشتق جهتی کمترین میزان ممکن را خواهد داشت.
 - در اینجا نیز با توجه به بسط تیلور تابع F حول X(k) به سادگی دیده می شود که اگر بردار جستجو در خلاف جهت گرادیان انتخاب شود، بیشترین تنزل در مقدار تابع F را خواهیم داشت.
 - الگوریتم بیشترین نزول برابر است با:

$$\underline{x}(k+1) = \underline{x}(k) - \alpha(k) \nabla F(\underline{x}(k))$$

- lpha(k) روش تعیین نرخ یادگیری lacktriangle
- $\alpha(k) = 2/k$ در نظر گرفتن یک مقدار ثابت. مثلا ۰.۰۵ یا -
- حداقل شود. $\alpha(k)$ در هر مرحله به گونه ای که تابع $\mathbf{F}(\mathbf{x}(\mathbf{k+1}))$ نسبت به $\alpha(k)$ خداقل شود. نرخ یادگیری بهینه



نكات مربوط به الگوريتم SD

• ثابت کنید نرخ یادگیری بهینه در الگوریتم SD برای توابع درجه دوم عبارتست از: (بخش V-V-T مطالعه شود)

$$\alpha_k = \frac{g_k^T g_k}{g_k^T A g_k}$$

• مراحل متوالى الگوريتم SD بر هم عمودند.